

Brief de arquitectura del agente

Veintinueve cosas que hay que construir para cerrar las brechas que encontró la evaluación del asesor guía web.

12 ago 2026 29 recomendaciones · 9 capas Evidencia: F-511 a F-534

LA IDEA PRINCIPAL

Casi ningún problema del agente es del modelo. Son de las capas que lo rodean: qué información puede consultar, qué herramientas tiene conectadas y qué reglas lo gobiernan. Si el planteo llega como «el agente responde mal», la conversación se va a ir a ajustar el prompt y no va a resolver nada.

La prueba: el agente **falla en dos direcciones opuestas**. Se niega a resolver una suma que sí podía hacer, y omite cinco datos públicos que sí conocía. Eso no es falta de cautela ni exceso de cautela — **es que nadie definió qué debe responder y qué no.**

RESUMEN

Las 29 en una página

Cada recomendación indica de dónde salió y en qué bloque de trabajo entra. El detalle de cada una viene después.

E Evaluación del asesor web · 5 L Literatura · 15 L+E Las dos coinciden · 9			
#	RECOMENDACIÓN	ORIGEN	BLOQUE
A · Conocimiento y contenido			
A1	Catálogo de productos con estado comercial	E	0
A2	Condicionados como fuente consultable	E	1
A3	Tabla de datos autorizados	L+E	1
A4	Revisión automática antes de responder	L+E	1
A5	Links tomados del catálogo	E	1

#	RECOMENDACIÓN	ORIGEN	BLOQUE
B · Herramientas y acción			
B1	Los cálculos los hace una calculadora, no el modelo	◆ L+E	1
B2	Lectura de la póliza del cliente identificado	▲ L	5
B3	Hacer los trámites, no explicarlos	▲ L	5
C · Reglas y límites			
C1	Tres reglas separadas, no una sola	◆ L+E	4
C2	Un motivo distinto por cada negativa	■ E	4
C3	Guion fijo para emergencias	◆ L+E	2
C4	Nada generado sobre el cuerpo	▲ L	2
C5	Revalidar las reglas en cada turno	▲ L	2
D · Conversación			
D1	Preguntar solo si cambia la respuesta	▲ L	5
D2	Memoria de la conversación	▲ L	5
D3	Evaluar el turno posterior a la repregunta	▲ L	5
E · Paso a un humano			
E1	Derivar según de quién fue la falla	▲ L	2
E2	Salida a humano siempre visible	▲ L	2
F · Comercial			
F1	Detectar interés real, no palabras clave	◆ L+E	6
F2	Ofrecer después de resolver	◆ L+E	6
F3	Cuándo avisar que es una IA	▲ L	6
G · Proactividad			
G1	Avisos que inicia el agente	▲ L	6

#	RECOMENDACIÓN	ORIGEN	BLOQUE
H • Cumplimiento			
H1	Reconocer un reclamo cuando llega	▲ L	3
H2	Guardar lo que el agente afirmó	◆ L+E	3
H3	Separar uso de atención y uso comercial	▲ L	3
I • Medición			
I1	El banco de 20 preguntas como control automático	■ E	1
I2	Medir también lo que el agente calla	◆ L+E	4
I3	Métricas por tipo de consulta	▲ L	4
I4	Medir el esfuerzo del cliente	▲ L	4

BLOQUE	QUÉ AGRUPA	POR QUÉ VA AHÍ
0	Bloqueante	Es el único riesgo de prometer algo que no se puede cumplir
1	Base de verdad	Cierra 6 de los 11 hallazgos y no requiere tocar el modelo
2	Seguridad clínica	Condición de salida para el ramo salud
3	Cumplimiento	Exposición regulatoria: corre en paralelo, no después
4	Control	Sin esto no se puede saber si algo mejoró
5	Experiencia	El salto real de autoatención al mudarse a la app
6	Comercial	Lo más débil en evidencia y lo que más riesgo agrega si se adelanta

DETALLE

Qué es cada una y por qué

A • Conocimiento y contenido La brecha más grande

A1 Catálogo de productos con estado comercial ■ E

- QUÉ Marcar cada producto como **venta nueva, solo renovación** o **discontinuado**. Si no es venta nueva, el agente no puede ofrecerlo.
- POR QUÉ Ofreció cotizar el Oncológico Integral, que hoy es solo renovaciones. No fue un descuido de redacción: **no tiene cómo saberlo**.

A2 Condicionados como fuente consultable ■ E

- QUÉ Indexar los condicionados con su versión, vigencia y plan asociado.
- POR QUÉ Los datos que omitió están en esos PDF. Hoy solo lee páginas de marketing, **que están escritas justamente para decir «revisa tu póliza»**.

A3 Tabla de datos autorizados ◆ L+E

- QUÉ Una tabla con plan, concepto, valor, vigencia y quién lo aprobó. El agente cita de ahí o no cita.
- POR QUÉ Carencia de maternidad, 60 días para inscribir al recién nacido, sumas aseguradas: **todos públicos, todos omitidos**. Y buscar dentro de textos largos no garantiza que el dato sea exacto ni que esté vigente (*An Industrial-Scale Insurance LLM, 2026*).

A4 Revisión automática antes de responder ◆ L+E

- QUÉ Un paso que compara la respuesta con las fuentes usadas y con la lista oficial de nombres. Si algo no calza, no sale.
- POR QUÉ Inventó «Salud Nacional» y «Programa Oncológico Integral». Es además el paso que la arquitectura de referencia del sector incluye como auto-verificación (*An Industrial-Scale Insurance LLM, 2026*).

A5 Links tomados del catálogo ■ E

- QUÉ Las direcciones las provee el catálogo, no las escribe el modelo, y se verifica que funcionen.
- POR QUÉ Un link de producto devolvió error 404.

B · Herramientas y acción Lo que el modelo no puede garantizar, que no lo haga el modelo

B1 Los cálculos los hace una calculadora, no el modelo ◆ L+E

- QUÉ** Deducible, coaseguro, saldo disponible, días a vencimiento y edad se calculan en una función. El modelo solo redacta el resultado.
- POR QUÉ** Se negó a resolver una suma simple. Y los modelos aciertan 95,6% cuando buscan un dato y **casi 0% cuando calculan con varias variables** (FAITH, 2025).

B2 Lectura de la póliza del cliente identificado ▲ L

- QUÉ** Definir qué campos puede leer el agente, con qué permiso y con qué registro de auditoría.
- POR QUÉ** En la app el cliente está identificado. **«Depende de tu plan» deja de ser prudencia: el agente sabe cuál es.** La evaluación no pudo ver esto porque se hizo sobre el agente web anónimo. Y hacer que el cliente vaya a buscar el dato es esfuerzo, que predice deslealtad mejor que la satisfacción (Dixon, Freeman & Toman, 2010).

B3 Hacer los trámites, no explicarlos ▲ L

- QUÉ** Reembolso, inclusión de dependiente, descarga de póliza y actualización de datos, resueltos dentro de la conversación.
- POR QUÉ** «Anda a la app y haz X», dicho **por** la app, es esfuerzo puro. Capturar una solicitud es fácil; resolverla es donde se cae: 96% de los avisos de siniestro entran sin humano pero solo 55% se resuelven de punta a punta (Lemonade, 2024).

C · Reglas y límites Hoy hay tres cosas distintas fundidas en una

C1 Tres reglas separadas, no una sola ◆ L+E

- QUÉ** Separar **seguridad, alcance de rol y política comercial**. La de seguridad debe mirar si la pregunta necesita datos privados, no de qué tema es.
- POR QUÉ** Los tres huecos aparecen en el banco: bloqueó una suma legítima, no puso límite cuando le preguntaron por fondos mutuos, y ofreció un producto que no correspondía. El diagnóstico de fondo: una frontera de conocimiento sin definir produce fallas en las dos direcciones a la vez (Kalai, Nachum, Vempala & Zhang, 2025). **El contenido de la política comercial lo define Negocio; arquitectura provee el mecanismo.**

C2 **Un motivo distinto por cada negativa** ■ E

QUÉ Cada rechazo lleva su propio código y su propio mensaje.

POR QUÉ Hoy usa el mismo texto ante una pregunta legítima de un cliente y ante un intento de abuso. Y sin códigos **tampoco se puede medir cuánto rechaza de más.**

C3 **Guion fijo para emergencias** ◆ L+E

QUÉ Ante señales de riesgo vital, una respuesta preescrita que se activa antes de llegar al modelo. Y nunca decir que el agente va a hacer algo que no puede hacer.

POR QUÉ Respondió bien, pero respondió **generando**. De 29 agentes evaluados ante riesgo suicida simulado, **ninguno** dio una respuesta adecuada, y el error más común fue prometer acciones que el sistema no puede ejecutar (*Scientific Reports, 2025*).

C4 **Nada generado sobre el cuerpo** ▲ L

QUÉ El agente no opina sobre síntomas, diagnóstico ni tratamiento. Es distinto de C3: C3 atiende la emergencia, C4 evita el consejo clínico en cualquier momento.

POR QUÉ Un chatbot de salud terminó recomendando déficit calórico a personas con trastornos alimentarios (*NEDA / Tessa, 2023*). Y en cinco años los evaluadores de síntomas **no mejoraron su precisión de triaje, y empeoraron justamente al indicar cuándo se requiere atención de emergencia** (*Schmieding et al., 2022*); la revisión sistemática del campo sitúa la precisión diagnóstica entre 5% y 50% (*Wallace et al., 2022*).

C5 **Revalidar las reglas en cada turno** ▲ L

QUÉ Las reglas se aplican turno a turno, no solo al empezar la conversación.

POR QUÉ Las protecciones **se aflojan en conversaciones largas** — justo el uso que queremos fomentar (*Scientific Reports, 2025*). Es lo más barato de construir de toda esta capa.

D • **Conversación** El banco es de un solo turno: no pudo evaluar nada de esto

D1 **Preguntar solo si cambia la respuesta** ▲ L

QUÉ Antes de repreguntar, revisar si la respuesta varía entre las pólizas del cliente. Si no varía, responder.

POR QUÉ Los modelos reconocen la ambigüedad y aun así responden sin preguntar (*Knowing but Not Showing, 2026*). Pero **cada pregunta de más es esfuerzo que el cliente paga**, y el esfuerzo predice deslealtad mejor que la satisfacción (*Dixon, Freeman & Toman, 2010*).

D2 Memoria de la conversación ▲ L

- QUÉ No repreguntar lo ya dicho, responder dos preguntas en un mismo mensaje, y aceptar «no, me refería al SOAT» sin reiniciar.
- POR QUÉ Coincide con lo que ya propuso Product Design, y el sesgo de no repreguntar **empeora conforme avanza el diálogo** (*Knowing but Not Showing, 2026*). Nadie lo ha probado todavía: el banco es de un solo turno.

D3 Evaluar el turno posterior a la repregunta ▲ L

- QUÉ Medir aparte la calidad de la respuesta que viene *después* de pedir una aclaración.
- POR QUÉ Ahí está el problema real, no en preguntar (*Clarification Is Not Enough, 2026*). **Un agente que pregunta mucho y responde mal es peor que uno que responde directo.**

E · Paso a un humano La capa que faltaba entera

E1 Derivar según de quién fue la falla ▲ L

- QUÉ Si la falla fue de la empresa, va a humano **aunque el agente sepa responder**. Si lo que corresponde es una disculpa, también. Si es una explicación o una compensación, puede resolverlo el agente.
- POR QUÉ Es la evidencia más sólida del expediente — tres experimentos en banca y salud. **El criterio no es qué tan complejo es el caso: es de quién fue la culpa.** Los clientes prefieren IA cuando la falla fue suya y humano cuando fue de la empresa; y prefieren humano cuando reciben una disculpa, pero aceptan IA con una explicación o una compensación (*Fürst, Trißler, Friedrich & Wirtz, 2025*). ⚠ Con una advertencia: prefieren un humano para resolver reclamos **incluso después de que un bot resolvió su caso con éxito** (*Chacon et al., 2026*).

E2 Salida a humano siempre visible ▲ L

- QUÉ Nunca escondida detrás de intentos del bot. Y ofrecida sola cuando detecta que el cliente está dando vueltas.
- POR QUÉ **Lo que enfurece no es que sea un bot: es no poder salir.** Un regulador lo documentó sobre 98 millones de usuarios de chatbots bancarios: bucles repetitivos, clientes mayores sin salida, y daño a la confianza en la institución, no solo en el canal (*CFPB, 2023*). La falla escala como frustración hacia la marca (*Ozuem et al., 2024*).

F · Comercial Lo más débil en evidencia

F1 Detectar interés real, no palabras clave ◆ L+E

- QUÉ Una pregunta comparativa debe pesar más que un «me interesa».
- POR QUÉ El agente conecta cuando oye vocabulario de compra y no conecta cuando alguien está comparando de verdad. **Está al revés:** decir «me interesa» no cuesta nada; comparar productos sí — es una señal costosa y por eso más diagnóstica (*Fitzsimons & Morwitz, citado en la evaluación*).

F2 Ofrecer después de resolver ◆ L+E

- QUÉ La oferta es un componente aparte, que se activa al final y se puede apagar sin tocar nada más.
- POR QUÉ Ante la señal de compra más clara del banco, la respuesta fue **la que menos conectó**. Y ofrecer antes de resolver cuesta confianza: la penalización por saber que se habla con una IA se reduce cuando se divulga *después* de haber ayudado (*Luo, Tong, Fang & Qu, 2019*).

F3 Cuándo avisar que es una IA ▲ L

- QUÉ Avisar es obligatorio. Lo que se decide es **en qué momento**.
- POR QUÉ Avisarlo antes de conversar redujo las compras cerca de 80% en un experimento de campo aleatorizado con una fintech real; avisarlo después de haber ayudado reduce ese castigo (*Luo, Tong, Fang & Qu, 2019*). **Toda proyección de venta calcada de un asesor humano está inflada.**

G · Proactividad Evidencia débil, pero es la única que hay

G1 Avisos que inicia el agente ▲ L

- QUÉ Póliza por vencer, saldo sin usar, reembolso en curso, chequeo preventivo incluido y no utilizado.
- POR QUÉ Es lo único documentado que mueve el uso recurrente: en el asistente bancario más grande del mundo, **entre 50% y 60% de las interacciones las inicia él** (*Bank of America, 2025*). ⚠ Pero no hay prueba causal — conviene construirlo como experimento medible, no como supuesto.

H · Cumplimiento En salud responden dos reguladores

H1 Reconocer un reclamo cuando llega ▲ L

- QUÉ Si el mensaje del cliente es un reclamo, se registra como reclamo y entra al flujo formal.
- POR QUÉ En salud responde **SUSALUD** además de SBS, con 30 días hábiles de plazo (*Ley 29414 y su reglamento; SUSALUD*). Y está documentado que los bots reconocen disputas solo por sintaxis específica (*CFPB, 2023*). **Es exposición regulatoria, no deuda técnica.**

H2 Guardar lo que el agente afirmó ◆ L+E

- QUÉ Registro de qué dijo, con qué fuente y a quién, guardado el tiempo que dure el contrato.
- POR QUÉ Un tribunal ya definió que **la empresa responde por lo que dice su chatbot**, sea contenido estático o conversacional (*Moffatt v. Air Canada, 2024*). Y con la oferta del producto no vendible, hoy no podríamos reconstruir qué se le prometió a quién.

H3 Separar uso de atención y uso comercial ▲ L

- QUÉ La conversación clínica no alimenta la venta sin un consentimiento propio para eso.
- POR QUÉ Los datos de salud son **datos sensibles**: usarlos con otra finalidad requiere otro permiso (*Ley 29733 y D.S. 003-2013-JUS*). Es el punto donde el objetivo comercial choca con el ramo.

I • Medición Lo que evita que todo lo anterior se degrade

I1 El banco de 20 preguntas como control automático ■ E

- QUÉ Correrlo en cada despliegue, con las respuestas correctas validadas por Producto.
- POR QUÉ Es el activo más valioso que dejó este trabajo y hoy no está en ningún pipeline. Sin respuesta validada, **el control no tiene contra qué comparar.**

I2 Medir también lo que el agente calla ◆ L+E

- QUÉ Que omitir un dato disponible cuente como error, y que decir «no lo tengo» cuando de verdad no lo tiene **sume puntos.**
- POR QUÉ 5 de 20 respuestas omitieron datos públicos. Y castigar el «no sé» le enseña al sistema a inventar: las evaluaciones que penalizan la abstención **fuerzan estadísticamente la alucinación** (*Kalai, Nachum, Vempala & Zhang, 2025*). **Son las dos caras de la misma decisión**, y explican por qué el agente falla en ambas direcciones.

I3 Métricas por tipo de consulta ▲ L

- QUÉ Medir resolución por tipo de consulta, no un porcentaje global de casos que no llegaron a un humano.
- POR QUÉ La marcha atrás más conocida del sector ocurrió porque **el promedio tapaba el deterioro en casos específicos** (Klarna, 2025).

I4 Medir el esfuerzo del cliente ▲ L

- QUÉ Turnos hasta resolver, repeticiones, cambios de canal, reformulaciones.
- POR QUÉ Cambio de canal, contactos repetidos y volver a explicar son los mayores generadores de esfuerzo, y **el esfuerzo predice la lealtad mejor que la satisfacción** (Dixon, Freeman & Toman, 2010).

ANTES DE EMPEZAR

Cuatro decisiones que no son de arquitectura

Conviene llevarlas explícitas para que la reunión no se atasque discutiéndolas.

Confirmar si el Oncológico Integral se vende → Producto Arquitectura construye el mecanismo de A1; alguien tiene que cargar el estado.
Aprobar la tabla de datos autorizados → Producto y Legal Sin esa firma A3 no puede salir. Es la dependencia externa más crítica del plan.
Definir cuándo no vender → Negocio y CoE Es una política de negocio; arquitectura solo provee el mecanismo que la hace ejecutable.
Permiso para uso comercial de la conversación clínica → Legal De esto depende H3, y con él todo el bloque comercial.

REFERENCIAS

En qué se apoya cada recomendación

Todas las fuentes marcadas como literatura, con su identificador en el código del proyecto. Se citan en el texto como (autor, año).

REVISTAS ARBITRADAS

F-517	Luo, X., Tong, S., Fang, Z. & Qu, Z. (2019). Frontiers: Machines vs. Humans — The Impact of Artificial Intelligence Chatbot Disclosure on Customer Purchases. <i>Marketing Science</i> , 38(6). Experimento de campo aleatorizado a gran escala en una fintech real. Usada en F2, F3.
F-515	Fürst, A., Trißler, L., Friedrich, R. & Wirtz, J. (2025). Service recovery by AI or human agents: Do failure and strategy context matter? <i>Journal of Service Management</i> , 36(3), 390-418. Tres experimentos con escenarios en banca y salud. Usada en E1.
F-515	Chacon, A. et al. (2026). Chatbot or Human? Rethinking Complaint Handling in Customer Service. <i>Journal of Consumer Behaviour</i> . Cuatro estudios preregistrados. Usada en E1.
F-516	Ozuem, W. et al. (2024). Exploring the relationship between chatbots, service failure recovery and customer loyalty: A frustration-aggression perspective. <i>Psychology & Marketing</i> . Usada en E2.
F-526	Wallace, W., Chan, C., Chidambaram, S. et al. (2022). The diagnostic and triage accuracy of digital and online symptom checker tools: a systematic review. <i>npj Digital Medicine</i> , 5:118. Revisión sistemática. Usada en C4.
F-526	Schmieding, M.L., Kopka, M., Schmidt, K., Schulz-Niethammer, S., Balzer, F. & Feufel, M.A. (2022). Triage Accuracy of Symptom Checker Apps: 5-Year Follow-up Evaluation. <i>JMIR</i> , 24(5):e31810. Usada en C4.
F-529	Ayers, J.W. et al. (2023). Comparing Physician and Artificial Intelligence Chatbot Responses to Patient Questions Posted to a Public Social Media Forum. <i>JAMA Internal Medicine</i> , 183(6), 589-596. Contexto del registro empático; no sustenta ninguna recomendación por sí sola.
F-531	Performance of mental health chatbot agents in detecting and managing suicidal ideation (2025). <i>Scientific Reports (Nature)</i> . Escenarios simulados. Usada en C3, C5.

PREPRINTS Y BENCHMARKS TÉCNICOS

F-512	Kalai, A.T., Nachum, O., Vempala, S. & Zhang, E. (2025). Why Language Models Hallucinate. <i>arXiv:2509.04664</i> . Usada en C1, I2.
F-511	Knowing but Not Showing: LLMs Recognize Ambiguity but Rarely Ask Clarifying Questions (2026) y Clarification Is Not Enough (2026). <i>arXiv</i> . Hallazgo replicado en cuatro trabajos independientes. Usadas en D1, D2, D3.
F-514	FAITH y benchmarks de razonamiento numérico (2025-2026). <i>arXiv</i> . Usada en B1.
F-513	An Industrial-Scale Insurance LLM Achieving Verifiable Domain Mastery and Hallucination Control (2026). <i>arXiv</i> . ⚠️ Preprint de autores de industria describiendo su propio sistema, sin reproducción independiente. Usada en A3, A4.

REGULADORES, NORMATIVA Y JURISPRUDENCIA

- F-533 **Ley N° 29414** y su reglamento — derechos de las personas usuarias de los servicios de salud; **SUSALUD**, procedimiento de reclamos. Usadas en H1.
- F-533 **Ley N° 29733** de Protección de Datos Personales y **D.S. 003-2013-JUS**. Los datos de salud son datos sensibles. Usadas en H3.
- F-518 **Moffatt v. Air Canada (2024)**. Civil Resolution Tribunal de Columbia Británica, 2024 BCCRT 149. ⚠ Tribunal de cuantía menor, sin precedente vinculante fuera de su jurisdicción. Usada en H2.
- F-519 **Consumer Financial Protection Bureau (2023)**. Chatbots in consumer finance — Issue Spotlight. 98 millones de usuarios de chatbots bancarios en 2022. Usada en E2, H1.

EMPRESAS Y CONSULTORÍA – AUTORREPORTADO, SIN AUDITAR

- F-522 **Bank of America (2025)**. Comunicados institucionales sobre el asistente Erica. ⚠ Métricas de definición propia sin metodología publicada. Usada en G1.
- F-523 **Klarna (2025)**, declaraciones de su CEO vía Forbes sobre la reversión del reemplazo de atención humana. ⚠ Las cifras originales de 2024 nunca fueron auditadas. Usada en I3.
- F-524 **Lemonade (2024)**. 96% de avisos de siniestro sin humano; 55% resueltos de punta a punta. ⚠ Cifras de la empresa reproducidas por terceros con interés comercial. Usada en B3.
- F-525 **Dixon, M., Freeman, K. & Toman, N. (2010)**. Stop Trying to Delight Your Customers. Harvard Business Review / CEB-Gartner, Customer Effort Score. ⚠ Investigación propietaria no auditable; la cifra ancla circula desde 2010 sin dataset público — se usa el mecanismo, no el multiplicador. Usada en B2, D1, I4.
- F-530 **NEDA / Tessa (2023)**, vía NPR, CBS y BBC. Retiro del chatbot en menos de 24 horas. Usada en C4.

CITADA DENTRO DE LA EVALUACIÓN, NO VERIFICADA POR SEPARADO

- **Fitzsimons & Morwitz** — efecto de mera medición, citado en el registro de la evaluación como fundamento de que una pregunta comparativa es señal más diagnóstica que una declaración de interés. Usada en F1.

SOBRE ESTE DOCUMENTO

Cruza dos fuentes: la evaluación del asesor guía web sobre un banco de 20 preguntas verificadas contra fuentes oficiales, y dos investigaciones sobre capacidades de asistentes de IA en seguros y en salud. Cada afirmación de origen literatura está trazada a su fuente y a su nivel de rigurosidad en el código del proyecto, F-511 a F-534.

Lo que no sabemos: no hay evidencia causal de que un asistente en la app aumente el uso recurrente ni la venta cruzada en seguros; no existe ningún caso peruano ni latinoamericano medido; la evidencia de negocio es autorreporte de empresas sin auditar; y no se halló pronunciamiento de SUSALUD sobre agentes conversacionales — lo cual es un vacío, no una autorización.