

Brief de arquitectura del agente

Veintinueve recomendaciones para cerrar las brechas que reveló la evaluación del asesor guía web, cruzadas con la evidencia disponible. Cada una marcada según de dónde viene.

12 ago 2026 v1 29 recomendaciones · 9 capas Evidencia: F-511 a F-534

LO PRIMERO QUE CONVIENE DECIR EN LA MESA

De los 11 hallazgos de la evaluación, 8 no son problemas del modelo. Son problemas de las capas que lo rodean: qué corpus puede consultar, qué herramientas tiene conectadas y qué políticas lo gobiernan. Si el planteo llega como «el agente responde mal», la conversación se va a ir a ajuste de prompt y no va a resolver nada.

La prueba está en que el agente falla en **dos direcciones opuestas a la vez:** rechaza una aritmética que sí podía resolver (P3) y omite cinco cifras públicas que sí conocía (P4, P6, P7, P9, P10). Eso no es un modelo mal calibrado — es que nadie definió dónde termina lo que debe responder.

CÓMO LEER LAS MARCAS

De dónde viene cada recomendación

La evaluación encontró los síntomas. La literatura aporta la mayoría de las capas que faltan. Donde las dos coinciden, la recomendación es más fuerte que cualquiera de las dos por separado — y es por ahí por donde conviene empezar.

■ EVALUACIÓN	▲ LITERATURA
5 Salen de la performance observada del asesor guía web sobre el banco de 20 preguntas. Son específicas de nuestro caso y no se habrían encontrado leyendo literatura.	15 Salen de la evidencia externa. No aparecen en la evaluación porque el banco no las probó — no porque el agente las tenga resueltas.

♦ CONVERGEN

9

Las dos fuentes apuntan al mismo componente por caminos independientes.
Máxima prioridad.

LAS NUEVE CAPAS

Recomendaciones

A • Conocimiento y contenido La brecha más grande

- A1 **Catálogo de producto como sistema de registro, con estado comercial** ■ E
- Campo estado_comercial — venta nueva / solo renovación / discontinuado — y regla dura: si no es venta nueva, la capa de generación no puede emitir una oferta.
- Origen:** P19 y P6. El agente ofreció cotizar el Oncológico Integral, que la página oficial marca como «solo aplica renovaciones». No es un error de redacción: **el estado comercial no existe como dato consultable**. Único riesgo de promesa incumplible en producción — bloqueante.
- A2 **Conicionados como corpus gobernado, versionado y atribuido a plan** ■ E
- Ingesta de los condicionados con versión, vigencia y atribución a plan — hoy el agente consulta páginas de marketing y centro de ayuda.
- Origen:** las cinco omisiones (P4, P6, P7, P9, P10). Los números que faltan viven en los PDF, y las páginas que sí consulta están escritas justamente para decir «revisa tu póliza». **El agente hace exactamente lo que su corpus le permite.**
- A3 **Catálogo de hechos autorizados, estructurado — no prosa recuperada** ♦ L+E
- Tabla plan · concepto · valor · vigencia · fuente · aprobado_por. El agente cita de ahí o no cita.
- Evaluación:** carencia de maternidad, 60 días de recién nacido, sumas de S/3,2M a S/5M — todas públicas, todas omitidas. **Literatura:** RAG sobre prosa no da garantía de exactitud ni de vigencia; la arquitectura de referencia del dominio separa la identificación de frontera de conocimiento como tarea propia.

A4

Validación post-generación contra catálogo y fuentes ◆ L+E

Etapla separada de la generación que contrasta la respuesta contra las fuentes recuperadas y contra la lista controlada de entidades. Si aparece un nombre que no está en el catálogo, o una afirmación que no se sostiene en lo recuperado, la respuesta no sale.

Evaluación: P1, P5 y P6 — «Salud Nacional» y «Programa Oncológico Integral» son nombres plausibles que el modelo compuso. **Literatura:** la única arquitectura publicada de LLM de seguros a escala industrial descompone el RAG en cuatro tareas, y la cuarta es corrección de alucinación posterior a la generación. La validación de nombres es el caso particular; la auto-verificación contra fuentes es el mecanismo general — **un solo componente resuelve los dos.**

A5

Links desde el catálogo, nunca generados ■ E

URLs provistas por el catálogo, con chequeo de salud en el pipeline de ingesta.

Origen: el 404 de P6 indica composición de URL o índice desactualizado.

B · Herramientas y acción Sacar del modelo lo que el modelo no puede garantizar

B1

Calculadora de gasto de bolsillo como herramienta determinista ◆ L+E

Deducible, coaseguro, copago, saldo de suma asegurada, días a vencimiento, edad vs. límite. El modelo redacta el resultado; no lo calcula.

Evaluación: P3, rechazo ante una aritmética resoluble con los datos dados. **Literatura:** los modelos de frontera pasan de 95,6% de acierto en búsqueda simple a prácticamente 0% en cálculo multivariado, y un error temprano se propaga por toda la cadena.

B2

Consulta de póliza autenticada, con capa de identidad y entitlements ▲ L

Contrato de la herramienta, qué campos puede leer, con qué base de consentimiento y con qué registro de auditoría.

Origen: el asistente de la app opera con cliente autenticado. Eso cambia el requisito de fondo — «depende de tu plan» deja de ser resguardo y pasa a ser evasión, porque el agente sabe cuál es el plan. **La evaluación no pudo detectar esto porque se hizo sobre el agente web anónimo.**

B3

Capa de ejecución de trámites, no solo de explicación ▲ L

Reembolso, inclusión de dependiente, descarga de póliza, actualización de datos: completarlos, no instruir cómo hacerlos.

Origen: en la aseguradora más automatizada del mundo, 96% de los avisos de siniestro entran sin humano pero solo 55% se resuelven de punta a punta. La brecha entre capturar y resolver es lo que separa un asistente informativo de uno que hace autoatención. Dentro de la app, «anda a la app y haz X» es esfuerzo puro.

C · Políticas y guardarrailes Hoy hay tres cosas fundidas en una

C1

Separar seguridad, alcance de rol y política comercial ◆ L+E

Tres políticas independientes con sus propios clasificadores. La de seguridad debe discriminar por **dependencia de dato**, no por tema. La comercial es la que aloja el criterio de «cuándo no vender».

Evaluación: los tres huecos aparecen en el banco — P3 (seguridad disparada sobre un cálculo legítimo), P14 (sin límite de rol: convierte una pregunta fuera de alcance en cross-sell) y P19 (sin política comercial: no reconoce el perfil de bajo riesgo antes de ofrecer).

Literatura: el diagnóstico de fondo es una frontera de conocimiento sin definir, que produce fallas en las dos direcciones a la vez. ⚠ El *contenido* de la política comercial lo define Negocio y el CoE; arquitectura provee el mecanismo que la hace ejecutable.

C2

Reason codes en cada rechazo, con mensajes diferenciados ■ E

Un código por tipo de rechazo y un mensaje propio para cada uno.

Origen: P3 usa el mismo texto genérico que se usaría ante un intento de jailbreak. Ante una pregunta legítima de un cliente, eso es un incidente de experiencia. Los códigos son además la única forma de **medir sobre-rechazo en producción**.

C3

Protocolo determinista de emergencia y crisis ◆ L+E

Intercepción fija antes del modelo para señales de riesgo vital. El agente nunca redacta como si él fuera a ejecutar la acción.

Evaluación: P13 salió bien, pero salió bien *generado*. **Literatura:** de 29 agentes evaluados ante riesgo suicida simulado, ninguno dio respuesta adecuada; el modo de falla más citado es prometer acciones que el sistema no puede ejecutar, lo que crea falsa seguridad y retrasa la atención real.

C4

Filtro de contenido clínico: nada generativo sobre síntomas, diagnóstico o tratamiento

▲ L

Distinto de C3: C3 intercepta la emergencia; C4 impide que el agente opine sobre el cuerpo en cualquier registro.

Origen: la asociación estadounidense de trastornos alimentarios retiró su chatbot en menos de 24 horas — al agregarle capacidad generativa, empezó a recomendar déficit calórico a personas con trastornos alimentarios. Y la precisión de triaje de los verificadores de síntomas lleva cinco años estancada en ~56%, omitiendo más del 40% de las emergencias.

C5

Re-afirmación de guardarraíles por turno, con límite de sesión ▲ L

Las políticas se revalidan en cada turno, no solo al inicio de la sesión.

Origen: las barandas de seguridad **se debilitan en conversaciones extendidas** — justo el patrón de uso que el producto quiere fomentar para engagement. Es la recomendación con mayor relación impacto/costo de esta capa, y el banco de 20 preguntas no podía detectarla porque es de un solo turno.

D • Conversación y estado Ausente por completo del brief original

D1

Desambiguación por varianza: preguntar solo si la respuesta cambia ▲ L

Antes de pedir aclaración, verificar si la respuesta varía entre las pólizas del cliente. Si no varía, responder.

Origen: los modelos tienen un sesgo consistente de sub-clarificación — reconocen la ambigüedad y responden igual, y empeora conforme avanza el diálogo. Pero **preguntar tampoco es gratis**: cada turno extra es esfuerzo que el cliente paga, y el esfuerzo predice deslealtad mejor que la satisfacción.

D2

Estado de sesión: memoria corta, multi-intención y aceptación de corrección

▲ L

No volver a preguntar lo ya establecido; separar y responder dos preguntas en un mensaje; aceptar «no, me refería al SOAT» sin reiniciar.

Origen: coincide con el bloque 3 de la propuesta de Product Design. El banco de 20 preguntas es de un solo turno, así que **no pudo evaluar nada de esto**.

D3

Evaluación propia del turno posterior a la aclaración ▲ L

Medir la calidad de la respuesta que sigue a una pregunta de desambiguación, como caso de prueba separado.

Origen: el cuello de botella documentado no es preguntar — es responder bien *después* de la aclaración. Un agente que pregunta mucho y responde mal después es peor que uno que responde directo.

E · Enrutamiento a humano La capa que más faltaba

E1

Enrutamiento por atribución de falla y carga emocional ▲ L

Dos criterios sobre el mismo servicio de enrutamiento. Falla de la empresa → humano, aunque el agente sepa la respuesta. Emoción negativa intensa → humano, sea cual sea el tema.

Origen: la mejor evidencia disponible de toda la investigación — artículo arbitrado con análisis de mediación. **El criterio de escalamiento no es la complejidad del caso, es de quién fue la culpa:** un rechazo de siniestro, una prima cobrada de más o un reembolso demorado son fallas de la empresa. Y el soporte informativo por IA es 37% menos efectivo cuando el cliente expresa emoción negativa intensa — condición frecuente en salud, no excepcional.

E2

Salida a humano: siempre disponible, y ofrecida al detectar bucle ▲ L

Nunca condicionada a un número mínimo de intentos del bot. Y un detector de repetición de consulta, turnos sin resolución y reformulaciones sucesivas que dispara la oferta de forma proactiva.

Origen: el regulador financiero estadounidense documentó, sobre 98 millones de usuarios, que los consumidores quedan atrapados en bucles repetitivos y que el efecto neto es **erosión de la confianza en la institución, no solo en el canal** — con impacto desproporcionado en clientes mayores. En todo el registro público, lo que enfurece no es que sea un bot: es quedarse sin salida.

F · Intención y puente comercial Donde la evaluación fue más específica y la literatura más incómoda

F1 Taxonomía pragmática de intención: informativa vs. consideración ◆ L+E

La clasificación hoy es léxica. Una pregunta comparativa bien formada debe pesar más que un «me interesa».

Evaluación: el agente conecta ante vocabulario de compra explícito (P17-P20) y no ante señal implícita (P1, P6, P9, P11). **Literatura:** un «me interesa» declarado cuesta cero decirlo; una pregunta comparativa revela esfuerzo cognitivo ya invertido. **La calibración está invertida.**

F2 Siguierte-mejor-acción desacoplada, y siempre posterior a la resolución ◆ L+E

Componente propio, apagable por política sin tocar el resto del sistema.

Evaluación: P16 es la señal de compra más explícita del banco y la respuesta con *menos* conexión comercial — el puente no funciona ni en el caso fácil. **Literatura:** la penalización de confianza obliga a resolver primero y ofrecer después.

F3 Política de divulgación de IA, con decisión sobre el momento ▲ L

Divulgar es obligatorio. Lo que sí se decide es *cuándo*.

Origen: en un experimento de campo aleatorizado a gran escala, divulgar la IA **antes** de la conversación redujo las compras cerca de 80%; el propio estudio reporta que la penalización se reduce al divulgar después de la interacción útil. Consecuencia directa: **toda proyección de cross-sell calcada de venta humana está inflada.**

G · Proactividad Evidencia débil, pero es el único mecanismo que hay

G1 Motor de disparadores proactivos sobre eventos de póliza ▲ L

Vencimiento próximo, saldo sin usar, avance de reembolso, chequeo preventivo incluido y no utilizado.

Origen: en el asistente bancario más grande del mundo, entre 50% y 60% de las interacciones **las inicia el asistente**. Es el único mecanismo de engagement documentado. ⚠ Pero es autorreporte corporativo sin auditar y no existe prueba causal — **construirlo como experimento medible, no como supuesto.**

H · Cumplimiento y trazabilidad Dos reguladores, no uno

H1

Clasificador de reclamo con integración al sistema de reclamos ▲ L

Si lo que el cliente escribe constituye un reclamo, se registra como reclamo — no se responde como consulta.

Origen: en salud operamos bajo SBS y **SUSALUD**. Un reclamo dispara un plazo regulado de 30 días hábiles. Y está documentado que los bots reconocen disputas solo por sintaxis específica: se les escapan. **Es exposición regulatoria, no deuda técnica.**

H2

Registro inmutable de afirmaciones por sesión ◆ L+E

Qué se afirmó, con qué fuente y versión, a qué cliente y cuándo. Retención alineada al periodo contractual.

Literatura: un tribunal rechazó el argumento de que el chatbot es una entidad separada — la empresa responde por toda la información que publica, sea estática o conversacional.

Evaluación: P19 es exactamente una promesa potencialmente incumplible, y hoy no habría forma de reconstruir qué se prometió.

H3

Vinculación de finalidad sobre dato sensible ▲ L

Separar técnicamente el uso prestacional del uso comercial de la conversación clínica, con bases de consentimiento distintas.

Origen: los datos de salud son **dato sensible** bajo Ley 29733, con régimen reforzado de finalidad. Usar la conversación clínica para alimentar cross-sell es usar dato sensible con una finalidad distinta de aquella para la que se recogió. Es el punto donde el objetivo comercial choca con el ramo.

I · Observabilidad y evaluación Lo que evita que todo lo anterior se degrade

I1

La suite de 20 preguntas como gate de regresión, con referencias validadas

■ E

De ejercicio puntual a control automático en cada despliegue — con la columna de respuesta de referencia validada por Producto, que hoy está incompleta.

Origen: es el activo más valioso que salió de este trabajo y no está incorporado a ningún pipeline. La referencia validada no es un refinamiento: **sin ella el gate no tiene contra qué comparar**, y es una limitación que la propia evaluación declara.

- I2

Rúbrica bidireccional: la omisión cuenta como defecto, la abstención correcta puntúa a favor

◆ L+E

Un tablero que solo mide alucinación no ve el defecto dominante de este agente, y una rúbrica que castiga el «no sé» produce el defecto contrario.

Evaluación: 5 de 20 respuestas omitieron un dato público que el agente podía dar.

Literatura: los regímenes de evaluación que penalizan la abstención **fuerzan estadísticamente la alucinación** — el sistema aprende que adivinar rinde más que decir que no sabe. Las dos mitades son la misma decisión de diseño de la rúbrica, y reflejan la tesis central del brief: el agente falla en ambas direcciones.
- I3

Métricas segmentadas por tipo de interacción, nunca agregadas

▲ L

Resolución por tipo de consulta, no tasa de deflexión global.

Origen: la reversión más conocida del sector ocurrió porque **las métricas agregadas de volumen enmascararon el deterioro de calidad en tipos específicos de interacción.** Gobernar el agente por tasa de deflexión reproduce ese error.
- I4

Instrumentar el esfuerzo del cliente

▲ L

Turnos hasta resolución, repeticiones, cambios de canal, reformulaciones.

Origen: los mayores generadores de esfuerzo documentados son exactamente los que produce un agente mal diseñado: cambio de canal, contactos repetidos y tener que volver a explicar. Y el esfuerzo predice lealtad mejor que la satisfacción.

SECUENCIA

Qué primero, y por qué

BLOQUE	QUÉ INCLUYE	POR QUÉ EN ESE ORDEN
0 • Bloqueante	A1	Único riesgo de promesa incumplible hoy en producción
1 • Base de verdad	A2, A3, A4, A5, B1, I1	Cierran 6 de los 11 hallazgos y no requieren tocar el modelo
2 • Seguridad clínica	C3, C4, C5, E1, E2	Condición de salida para el ramo salud; C5 es el de mejor relación impacto/costo
3 • Cumplimiento	H1, H2, H3	Exposición regulatoria — corre en paralelo, no después
4 • Control	C1, C2, I2, I3, I4	Sin reason codes y sin métrica de omisión no se puede medir si algo mejoró

BLOQUE	QUÉ INCLUYE	POR QUÉ EN ESE ORDEN
5 • Experiencia	B2, B3, D1, D2, D3	El salto real de autoatención al mudarse a la app
6 • Comercial	F1, F2, F3, G1	Lo más débil en evidencia y lo que más riesgo agrega si se adelanta

FUERA DE ARQUITECTURA

Decisiones que bloquean, y no son de este equipo

Conviene llevarlas explícitas para que la reunión no se atasque discutiéndolas.

Confirmar la disponibilidad comercial del Oncológico Integral → Producto Arquitectura construye el mecanismo de A1; alguien tiene que poblar el estado.
Aprobar la lista de hechos autorizados → Producto y Legal Sin esa firma, A3 no puede salir. Es la dependencia externa más crítica del plan.
Definir el criterio de «cuándo no vender» → Negocio y CoE Es una política de negocio; arquitectura solo provee el mecanismo (C1) que la hace ejecutable.
Base de consentimiento para uso comercial de conversación clínica → Legal y DPO H3 depende de esa definición, y condiciona todo el bloque comercial.

SOBRE ESTE DOCUMENTO

Cruce de dos fuentes: la evaluación del asesor guía web sobre un banco de 20 preguntas con verificación contra fuentes oficiales, y dos investigaciones de 360° sobre capacidades de asistentes de IA en seguros y en el ramo salud. Cada afirmación de la columna de literatura está trazada a su fuente y a su nivel de rigurosidad en el código del proyecto, F-511 a F-534.

Lo que este brief no resuelve: no existe evidencia causal de que un asistente in-app aumente engagement o venta cruzada en seguros; no hay ningún caso peruano ni latinoamericano medido; la evidencia de negocio es autorreporte corporativo sin auditar; y no se halló pronunciamiento de SUSALUD sobre agentes conversacionales — lo cual es un vacío, no una autorización.