

INVESTIGACIÓN · SEGUROS PERÚ

Predicción de churn y renovación en seguros.

Síntesis de la evidencia y propuesta de modelo, desagregada por ramo, región, Perú y NSE —
apoyada solo en fuentes de alta rigurosidad.

Documento de trabajo · Protocolo /seeker · 2026

QUÉ CUBRE ESTE DOCUMENTO

Del hallazgo a la propuesta de modelo.

01
Predictores transversales
Lo que opera en casi todos los ramos.

03
Por región
Qué amplifica LatAm frente a mercados maduros.

05
Propuesta de modelo
Dos targets, features, método y métricas.

02
Por ramo
Auto, hogar, salud, vida, comercial.

04
Perú y NSE A/B
Predictores estructurales y segmento voluntario.

06
Roadmap y rigor
Fases de implementación y límites de la evidencia.

El churn no es un evento: hay **dos churns** .

CHURN ACTIVO

El cliente decide irse.

Cotiza y se cambia por precio, servicio o competencia. Domina en mercados maduros y NSE A/B. Intervención comercial.

CAÍDA INVOLUNTARIA

El cliente deja de pagar.

No "decide": cae por impago (cobro fallido, shock de liquidez). Domina en el masivo peruano. Intervención operativa.

Modelarlos como un solo evento mezcla dos procesos y vuelve el modelo inaccionable.

01 — PREDICTORES

Qué predice renovación vs. churn .

Cinco niveles: transversal, ramo, región, Perú y NSE.

Lo que opera en casi todos los ramos .

01

Cambio de precio en renovación

El predictor más fuerte y consistente en P&C (Guelman & Guillén, 2014).

03

Bundling / n.º de pólizas

Multi-línea reduce el churn de forma marcada.

05

Método y frecuencia de pago

Débito automático y pago anual reducen la caída.

02

Antigüedad / duración

Churn alto al inicio y decreciente con el tenure.

04

Experiencia de siniestros

Un siniestro —y su insatisfacción o rechazo— sube el churn.

06

Canal y relación con el broker

La intermediación con asesoría retiene más.

Cada ramo tiene un predictor dominante .

RAMO	PREDICTOR DOMINANTE	OTROS FUERTES	NATURALEZA
Auto	Cambio de precio	Tenure, siniestro, bundling, telemática	Shopping activo
Hogar	Bundling	Rate change, tenure, siniestros grandes	No-renovación
Salud	Premium + red / elegibilidad	Star rating, empleo, disrupción admin.	Decisión + elegibilidad
Vida	Shock financiero / tasas	Duración temprana, canal, accesibilidad	Lapse / rescate
Comercial	Relación con el broker	Precio/ciclo, siniestros, tamaño	Re-cotización

Qué significa **cada término** .

Cambio de precio (rate change)

Variación de la prima al renovar respecto al periodo anterior.

Bundling

Tener varias pólizas con la misma aseguradora (ej. auto + hogar).

Red / elegibilidad

Clínicas y médicos afiliados al plan; y condiciones (empleo, edad) que habilitan la cobertura.

Disrupción administrativa

Cambios del plan que rompen la renovación automática y fuerzan una decisión.

Shock financiero (EFH)

Caída de ingreso (ej. desempleo) que lleva a rescatar la póliza como fondo de emergencia.

Shopping activo

El cliente compara precios entre aseguradoras y se cambia por decisión propia.

Premium

La prima: el monto que el cliente paga (mensual o anual) por mantener su cobertura.

Duración temprana

Los primeros 1–2 años de la póliza: el tramo donde la caída (lapse) es más alta.

Accesibilidad

Peso de la prima en el ingreso del cliente; a mayor peso, más difícil sostener el pago.

Tenure

Antigüedad de la póliza: meses o años desde su emisión.

Telemática

Datos de manejo del vehículo (app/dispositivo) que ajustan la prima al comportamiento.

Star rating

Calificación pública de calidad del plan de salud (1–5 estrellas, contexto EE.UU.).

Lapse / rescate

Caída de la póliza de vida por dejar de pagar (lapse) o retiro anticipado del valor acumulado (rescate).

Tasas (IRH)

Con tasas de interés altas, el cliente rescata para reinvertir en productos más rentables.

Re-cotización

En seguros comerciales, volver a licitar la cuenta con varias aseguradoras en cada renovación.

Tamaño (de cuenta)

Volumen de prima del cliente corporativo; las cuentas grandes negocian y re-cotizan más en cada renovación.

Canal

Por dónde se vendió y gestiona la póliza: broker, bancaseguros, asesor directo o digital.

No todas las variables **pesan igual** .

VARIABLE	PODER PREDICTIVO	SUSTENTO	¿ACCIONABLE?
Cambio de precio en renovación	●●● Alto	Consistente entre estudios; elasticidad precio-renovación (Guelman & Guillén, 2014)	Parcial — tiene costo
Método / timing de pago	●●● Alto	Crítico para impago; liquidez en emergentes (Eling, 2014)	Sí — migrar a débito
Tenure / duración temprana	●●● Alto	Consistente entre ramos; lapse mayor en años 1–2 (EAJ, 2022)	No — pero segmenta
Bundling / n.º de pólizas	●●● Alto	Recurrente en modelos ML de aseguradoras	Sí — cross-sell
Siniestro y su satisfacción	●●○ Medio-alto	Eleva el lapse en promedio (Guillén et al., 2003); lo que dispara es el rechazo y el Δ prima posterior; contagio al resto del hogar (Brockett et al., 2008)	Sí — experiencia
Canal / relación con broker	●●○ Medio-alto	Fuerte en Perú: la confianza sube con broker (SBS, 2023)	Sí
Shock de ingreso (EFH)	●●○ Medio	La más respaldada en vida (Outreville, 1990); mixta según mercado	No — mitigable
Tasas de interés (IRH)	●○○ Bajo-medio	Evidencia mixta; solo vida-ahorro	No

Los pesos exactos salen de la data propia al entrenar: no existen coeficientes públicos medidos en Perú.

El siniestro no predice: predice **su resolución** .

EN PROMEDIO

Tener un siniestro eleva el churn.

Documentado con datos reales de aseguradora (Guillén et al., 2003). Parte del efecto es la **anticipación del aumento de prima** que sigue al siniestro.

PERO ES CONDICIONAL

El disparador real es el resultado.

Rechazo, demora o mala resolución — y el **Δ prima posterior**. La revisión sistemática (Geneva Papers, 2020) muestra que "tuvo siniestro" a secas es un mal predictor aislado.

MOMENTO DE LA VERDAD

Bien resuelto, retiene.

El cliente bien atendido en el momento de estrés muestra lealtad igual o mayor que quien nunca usó el seguro (evidencia de industria, direccional).

EFFECTO CONTAGIO (BROCKETT ET AL., 2008)

Una póliza cancelada arriesga al cliente completo.

Análisis de supervivencia sobre portafolios de hogares: al cancelar una póliza, sube fuertemente la probabilidad de cancelar **las demás del hogar**, y la deserción total ocurre en una **ventana corta**. Un siniestro mal manejado no pierde una póliza: pierde al cliente — y hay poco tiempo para reaccionar.

SEÑALES PARA EL MODELO

Qué medir, en vez del binario.

Resultado del siniestro (pagado / rechazado) · **tiempo de resolución** · **satisfacción** post-atención · **Δ prima en la renovación siguiente** · **cancelación reciente de otra póliza** del cliente (la alerta de contagio).

LatAm **amplifica** predictores estructurales.

PREDICTOR	MERCADOS MADUROS	LATAM
Precio / rate change	Dominante (auto/hogar)	Fuerte, vía accesibilidad
Liquidez / timing de pago	Menor	Dominante (informalidad)
Confianza institucional	Se da por sentada	Predictor activo
Bancarización / medio de pago	Relevante	Más fuerte (impago)
Shock de empleo (EFH)	Moderado	Amplificado

En Perú domina la **caída involuntaria** .

PAGO

Fricción de cobro

Baja bancarización limita el débito automático → caída por impago, no por decisión.

CONTEXTO

Informalidad >73%

Ingreso volátil → shock de liquidez (hipótesis del fondo de emergencia).

REGULACIÓN

Desgravamen opcional

Dejó de ser obligatorio salvo hipotecas: quiebre estructural en la serie.

CONFIANZA

~48% desconfía

Causa #1: falta de información. La confianza sube con el broker.

MEDICIÓN

Confusión SIS/EsSalud

70% asocia "seguro" con salud pública → contamina la variable objetivo.

SESGOS

Present bias e inercia

La inercia retiene al inscrito, pero produce la caída silenciosa por impago.

NSE A/B concentran el **mercado voluntario** .

≈12%

de los hogares del país son NSE A (1.2%) + B (10.6%) —
APEIM 2024.

S/ 8,117

ingreso mensual promedio NSE AB vs. S/ 3,348 nacional.

Activo

su churn es decisión (precio/servicio), no impago:
bancarización casi universal.

Es el segmento del perfilador de venta ("creación de patrimonio"). NSE entra como **feature**, no como partición del modelo.

02 — PROPUESTA DE MODELO

Un modelo que separa los dos churns

Desagrega por NSE o perfil solo donde el mecanismo cambia.

Dos **targets** , no uno.

TARGET A

Lapse involuntario (impago)

Predice el cobro fallido / no pago. Features: método de pago, atrasos, mora, formalidad. Sustento: liquidez en mercados emergentes (Eling, 2014; EFH, Outreville, 1990).

TARGET B

Baja voluntaria (no-renovación / rescate)

Predice la decisión activa. Features: Δ precio en renovación, competitividad, servicio. Sustento: elasticidad precio (Guelman & Guillén, 2014; lapse Lasso, 2022).

La intervención de A es operativa; la de B, comercial. Por eso van separados.

Targets × ramo; NSE como **feature**, no **partición** .

01

Corte primario: tipo de evento

A (involuntario) vs. B (voluntario) — justificado por mecanismo.

03

NSE / perfil: como feature

El impago lo predice el método de pago + formalidad, no la etiqueta NSE.

02

Corte secundario: ramo

Modelos por ramo o interacciones fuertes ramo × feature.

04

Desagregar solo si es necesario

Se prueba con datos si el churn de NSE A/B se comporta distinto al del resto; solo si la diferencia es material se entrenan modelos separados.

Principio de parsimonia: no segmentar por etiqueta, solo cuando el proceso generador del dato difiere.

CÓMO FUNCIONA

De los datos al **score mensual** por póliza.

01 · Entrada

Una foto mensual de cada póliza.

Historial de pagos (método, atrasos, cobros fallidos), precio y renovaciones, antigüedad, canal, siniestros y datos del cliente. Todo ya existe en los sistemas: no requiere data nueva.

02 · Dos modelos

Cada póliza recibe dos probabilidades.

Modelo A: probabilidad de caer por impago en los próximos 90 días. Modelo B: probabilidad de no renovar o rescatar en la próxima renovación. Se separan porque las causas y las acciones son distintas.

03 · Salida

Un score de 0 a 100 con su porqué.

Cada score viene con las 3 razones que más lo explican (ej. "cobro fallido hace 15 días + pago manual + primer año de póliza"). El equipo no recibe un número ciego, recibe una causa.

04 · Acción

El score dispara la ruta correcta.

Score A alto → gestión de cobro (migrar a débito, mover fecha, recordatorio). Score B alto → gestión comercial (contacto pre-renovación, oferta de valor, broker).

VALIDACIÓN

Cómo sabremos que **funciona de verdad** .

01 · Prueba honesta

Entrenar con el pasado, probar con el futuro.

El modelo se entrena con datos hasta una fecha de corte y se evalúa sobre los meses siguientes, que nunca vio. Así se simula exactamente cómo operará en producción.

02 · Precisión útil

De cada 100 pólizas que el modelo señala, ¿cuántas caen de verdad?

Y de las que efectivamente cayeron, ¿cuántas alcanzó a detectar a tiempo? Estas dos preguntas —no el "accuracy" global— son la vara, porque el churn es un evento raro: un modelo que dice "nadie cae" acierta 95% y no sirve de nada.

03 · Score confiable

Si el modelo dice 30%, debe caer el 30%.

Calibración: los scores tienen que reflejar probabilidades reales para poder priorizar cartera y dimensionar la gestión.

04 · La prueba final es de negocio

Piloto con grupo de control.

Se interviene a una parte de las pólizas de alto score y se compara contra un grupo igual sin intervención. El veredicto no es una métrica estadística: es la prima retenida adicional.

La intervención **depende del target** .

TARGET A · OPERATIVA

Asegurar el pago

Migrar a débito automático, ajustar la fecha de cobro a la liquidez, recordatorios, recuperación del cobro fallido. La palanca #1 del masivo peruano no es el precio.

TARGET B · COMERCIAL

Retener por valor

Contacto pre-renovación, retención por precio/valor, refuerzo del broker, mejora de la experiencia de siniestro.

Usar **uplift modeling**: actuar sobre quienes la intervención cambia, no sobre quienes caerían o renovarían igual.

CIERRE

Roadmap y nota de rigor.

Fase 0

Datos y target

Definir y etiquetar los dos eventos; marcar el structural break; auditar el objetivo.

Fase 2

Heterogeneidad

Probar si desagregar por NSE aporta sobre interacciones.

Fase 1

MVP por target × ramo

Base interpretable + GBM; PR-AUC, calibración, SHAP.

Fase 3

Uplift + operación

De propensión a uplift; conectar score → intervención; medir prima retenida.

Solo se usó evidencia ●A/●B. No hay coeficientes de churn medidos en Perú: los pesos reales salen de la data de RIMAC al entrenar.

FUENTES

La evidencia detrás de cada afirmación .

ACADÉMICAS PEER-REVIEWED (● ALTA RIGUROSIDAD)

Guelman & Guillén (2014). Elasticidad precio-renovación en seguros de auto. *Expert Systems with Applications*.

Eling, Pradhan & Schmit (2014). Determinantes de demanda y dropout en microseguros: liquidez y confianza. *The Geneva Papers*.

Outreville (1990). Lapse en vida y la hipótesis del fondo de emergencia (EFH). *J. of Risk and Insurance*.

European Actuarial Journal (2022). Determinantes de lapse en vida — selección Lasso; duración temprana.

Meyers et al. (2019). Premium y calidad como drivers de cambio de plan de salud. *JAMA Internal Medicine*. ⚠ Contexto EE.UU.

Platteau et al. (2021). Sesgos y puzzle del sub-aseguramiento. *J. of Behavioral & Experimental Finance*.

Guillén et al. (2003) y Brockett et al. (2008). Siniestro → lapse y contagio de cancelación en el hogar. *J. of Risk and Insurance*.

The Geneva Papers (2020). Revisión sistemática de cancelación en no-vida: el efecto del siniestro es condicional.

REGULADORES Y GREMIOS (● SÓLIDA)

SBS (2023). Estudio de conocimiento y percepción de la demanda de seguros en Perú: tenencia, confianza, rol del broker.

APEIM (2024). Niveles socioeconómicos 2023-2024: distribución e ingreso por NSE.

S&P Global Ratings (2024). LatAm Insurance Sector View: macro, lapse y rescates.

CONTEXTO DIRECCIONAL (●/● — NO FUNDAMENTA EL DISEÑO)

Mordor Intelligence (2025). Informalidad y bancarización en Perú.

SBS / prensa (2024). Cambio normativo del desgravamen (structural break). ⚠ Confirmar con la norma.

Registro completo con rigurosidad por fuente: [research/fuentes/registro_fuentes.md](#) (F-1, F-3, F-35 a F-48).