

INVESTIGACIÓN · SEGUROS PERÚ

Predicción de churn y renovación en seguros.

Síntesis de la evidencia y propuesta de modelo, desagregada por ramo, región, Perú y NSE —
apoyada solo en fuentes de alta rigurosidad.

Documento de trabajo · Protocolo /seeker · 2026

QUÉ CUBRE ESTE DOCUMENTO

Del hallazgo a la propuesta de modelo.

01
Predictores transversales
Lo que opera en casi todos los ramos.

03
Por región
Qué amplifica LatAm frente a mercados maduros.

05
Propuesta de modelo
Dos targets, features, método y métricas.

02
Por ramo
Auto, hogar, salud, vida, comercial.

04
Perú y NSE A/B
Predictores estructurales y segmento voluntario.

06
Roadmap y rigor
Fases de implementación y límites de la evidencia.

El churn no es un evento: hay **dos churns** .

CHURN ACTIVO

El cliente decide irse.

Cotiza y se cambia por precio, servicio o competencia. Domina en mercados maduros y NSE A/B. Intervención comercial.

CAÍDA INVOLUNTARIA

El cliente deja de pagar.

No "decide": cae por impago (cobro fallido, shock de liquidez). Domina en el masivo peruano. Intervención operativa.

Modelarlos como un solo evento mezcla dos procesos y vuelve el modelo inaccionable.

01 — PREDICTORES

Qué predice renovación vs. churn .

Cinco niveles: transversal, ramo, región, Perú y NSE.

Lo que opera en casi todos los ramos .

01

Cambio de precio en renovación

El predictor más fuerte y consistente en P&C (Guelman & Guillén, 2014).

03

Bundling / n.º de pólizas

Multi-línea reduce el churn de forma marcada.

05

Método y frecuencia de pago

Débito automático y pago anual reducen la caída.

02

Antigüedad / duración

Churn alto al inicio y decreciente con el tenure.

04

Experiencia de siniestros

Un siniestro —y su insatisfacción o rechazo— sube el churn.

06

Canal y relación con el broker

La intermediación con asesoría retiene más.

Cada ramo tiene un predictor dominante .

RAMO	PREDICTOR DOMINANTE	OTROS FUERTES	NATURALEZA
Auto	Cambio de precio	Tenure, siniestro, bundling, telemática	Shopping activo
Hogar	Bundling	Rate change, tenure, siniestros grandes	No-renovación
Salud	Premium + red / elegibilidad	Star rating, empleo, disrupción admin.	Decisión + elegibilidad
Vida	Shock financiero / tasas	Duración temprana, canal, accesibilidad	Lapse / rescate
Comercial	Relación con el broker	Precio/ciclo, siniestros, tamaño	Re-cotización

Qué significa **cada término** .

Cambio de precio (rate change)

Variación de la prima al renovar respecto al periodo anterior.

Bundling

Tener varias pólizas con la misma aseguradora (ej. auto + hogar).

Red / elegibilidad

Clínicas y médicos afiliados al plan; y condiciones (empleo, edad) que habilitan la cobertura.

Disrupción administrativa

Cambios del plan que rompen la renovación automática y fuerzan una decisión.

Shock financiero (EFH)

Caída de ingreso (ej. desempleo) que lleva a rescatar la póliza como fondo de emergencia.

Shopping activo

El cliente compara precios entre aseguradoras y se cambia por decisión propia.

Premium

La prima: el monto que el cliente paga (mensual o anual) por mantener su cobertura.

Tenure

Antigüedad de la póliza: meses o años desde su emisión.

Telemática

Datos de manejo del vehículo (app/dispositivo) que ajustan la prima al comportamiento.

Star rating

Calificación pública de calidad del plan de salud (1–5 estrellas, contexto EE.UU.).

Lapse / rescate

Caída de la póliza de vida por dejar de pagar (lapse) o retiro anticipado del valor acumulado (rescate).

Tasas (IRH)

Con tasas de interés altas, el cliente rescata para reinvertir en productos más rentables.

Re-cotización

En seguros comerciales, volver a licitar la cuenta con varias aseguradoras en cada renovación.

Tamaño (de cuenta)

Volumen de prima del cliente corporativo; las cuentas grandes negocian y re-cotizan más en cada renovación.

No todas las variables **pesan igual** .

VARIABLE	PODER PREDICTIVO	SUSTENTO	¿ACCIONABLE?
Cambio de precio en renovación	●●● Alto	Consistente entre estudios; elasticidad precio-renovación (Guelman & Guillén, 2014)	Parcial — tiene costo
Método / timing de pago	●●● Alto	Crítico para impago; liquidez en emergentes (Eling, 2014)	Sí — migrar a débito
Tenure / duración temprana	●●● Alto	Consistente entre ramos; lapse mayor en años 1–2 (EAJ, 2022)	No — pero segmenta
Bundling / n.º de pólizas	●●● Alto	Recurrente en modelos ML de aseguradoras	Sí — cross-sell
Siniestro y su satisfacción	●●○ Medio-alto	Recurrente; depende de la resolución	Sí — experiencia
Canal / relación con broker	●●○ Medio-alto	Fuerte en Perú: la confianza sube con broker (SBS, 2023)	Sí
Shock de ingreso (EFH)	●●○ Medio	La más respaldada en vida (Outreville, 1990); mixta según mercado	No — mitigable
Tasas de interés (IRH)	●○○ Bajo-medio	Evidencia mixta; solo vida-ahorro	No

Los pesos exactos salen de la data propia al entrenar: no existen coeficientes públicos medidos en Perú.

LatAm **amplifica** predictores estructurales.

PREDICTOR	MERCADOS MADUROS	LATAM
Precio / rate change	Dominante (auto/hogar)	Fuerte, vía accesibilidad
Liquidez / timing de pago	Menor	Dominante (informalidad)
Confianza institucional	Se da por sentada	Predictor activo
Bancarización / medio de pago	Relevante	Más fuerte (impago)
Shock de empleo (EFH)	Moderado	Amplificado

En Perú domina la **caída involuntaria** .

PAGO

Fricción de cobro

Baja bancarización limita el débito automático → caída por impago, no por decisión.

CONTEXTO

Informalidad >73%

Ingreso volátil → shock de liquidez (hipótesis del fondo de emergencia).

REGULACIÓN

Desgravamen opcional

Dejó de ser obligatorio salvo hipotecas: quiebre estructural en la serie.

CONFIANZA

~48% desconfía

Causa #1: falta de información. La confianza sube con el broker.

MEDICIÓN

Confusión SIS/EsSalud

70% asocia "seguro" con salud pública → contamina la variable objetivo.

SESGOS

Present bias e inercia

La inercia retiene al inscrito, pero produce la caída silenciosa por impago.

NSE A/B concentran el **mercado voluntario** .

≈12%

de los hogares del país son NSE A (1.2%) + B (10.6%) —
APEIM 2024.

S/ 8,117

ingreso mensual promedio NSE AB vs. S/ 3,348 nacional.

Activo

su churn es decisión (precio/servicio), no impago:
bancarización casi universal.

Es el segmento del perfilador de venta ("creación de patrimonio"). NSE entra como **feature**, no como partición del modelo.

02 — PROPUESTA DE MODELO

Un modelo que separa los dos churns

Desagrega por NSE o perfil solo donde el mecanismo cambia.

Dos **targets** , no uno.

TARGET A

Lapse involuntario (impago)

Predice el cobro fallido / no pago. Features: método de pago, atrasos, mora, formalidad. Sustento: liquidez en mercados emergentes (Eling, 2014; EFH, Outreville, 1990).

TARGET B

Baja voluntaria (no-renovación / rescate)

Predice la decisión activa. Features: Δ precio en renovación, competitividad, servicio. Sustento: elasticidad precio (Guelman & Guillén, 2014; lapse Lasso, 2022).

La intervención de A es operativa; la de B, comercial. Por eso van separados.

Targets × ramo; NSE como **feature**, no **partición** .

01

Corte primario: tipo de evento

A (involuntario) vs. B (voluntario) — justificado por mecanismo.

03

NSE / perfil: como feature

El impago lo predice el método de pago + formalidad, no la etiqueta NSE.

02

Corte secundario: ramo

Modelos por ramo o interacciones fuertes ramo × feature.

04

Desagregar solo si es necesario

Se prueba con datos si el churn de NSE A/B se comporta distinto al del resto; solo si la diferencia es material se entrenan modelos separados.

Principio de parsimonia: no segmentar por etiqueta, solo cuando el proceso generador del dato difiere.

CÓMO FUNCIONA

De los datos al **score mensual** por póliza.

01 · Entrada

Una foto mensual de cada póliza.

Historial de pagos (método, atrasos, cobros fallidos), precio y renovaciones, antigüedad, canal, siniestros y datos del cliente. Todo ya existe en los sistemas: no requiere data nueva.

02 · Dos modelos

Cada póliza recibe dos probabilidades.

Modelo A: probabilidad de caer por impago en los próximos 90 días. Modelo B: probabilidad de no renovar o rescatar en la próxima renovación. Se separan porque las causas y las acciones son distintas.

03 · Salida

Un score de 0 a 100 con su porqué.

Cada score viene con las 3 razones que más lo explican (ej. "cobro fallido hace 15 días + pago manual + primer año de póliza"). El equipo no recibe un número ciego, recibe una causa.

04 · Acción

El score dispara la ruta correcta.

Score A alto → gestión de cobro (migrar a débito, mover fecha, recordatorio). Score B alto → gestión comercial (contacto pre-renovación, oferta de valor, broker).

VALIDACIÓN

Cómo sabremos que funciona de verdad .

01 · Prueba honesta

Entrenar con el pasado, probar con el futuro.

El modelo se entrena con datos hasta una fecha de corte y se evalúa sobre los meses siguientes, que nunca vio. Así se simula exactamente cómo operará en producción.

02 · Precisión útil

De cada 100 pólizas que el modelo señala, ¿cuántas caen de verdad?

Y de las que efectivamente cayeron, ¿cuántas alcanzó a detectar a tiempo? Estas dos preguntas —no el "accuracy" global— son la vara, porque el churn es un evento raro: un modelo que dice "nadie cae" acierta 95% y no sirve de nada.

03 · Score confiable

Si el modelo dice 30%, debe caer el 30%.

Calibración: los scores tienen que reflejar probabilidades reales para poder priorizar cartera y dimensionar la gestión.

04 · La prueba final es de negocio

Piloto con grupo de control.

Se interviene a una parte de las pólizas de alto score y se compara contra un grupo igual sin intervención. El veredicto no es una métrica estadística: es la prima retenida adicional.

La intervención **depende del target** .

TARGET A · OPERATIVA

Asegurar el pago

Migrar a débito automático, ajustar la fecha de cobro a la liquidez, recordatorios, recuperación del cobro fallido. La palanca #1 del masivo peruano no es el precio.

TARGET B · COMERCIAL

Retener por valor

Contacto pre-renovación, retención por precio/valor, refuerzo del broker, mejora de la experiencia de siniestro.

Usar **uplift modeling**: actuar sobre quienes la intervención cambia, no sobre quienes caerían o renovarían igual.

CIERRE

Roadmap y nota de rigor.

Fase 0

Datos y target

Definir y etiquetar los dos eventos; marcar el structural break; auditar el objetivo.

Fase 2

Heterogeneidad

Probar si desagregar por NSE aporta sobre interacciones.

Fase 1

MVP por target × ramo

Base interpretable + GBM; PR-AUC, calibración, SHAP.

Fase 3

Uplift + operación

De propensión a uplift; conectar score → intervención; medir prima retenida.

Solo se usó evidencia ●A/●B. No hay coeficientes de churn medidos en Perú: los pesos reales salen de la data de RIMAC al entrenar.

FUENTES

La evidencia detrás de cada afirmación .

ACADÉMICAS PEER-REVIEWED (● ALTA RIGUROSIDAD)

Guelman & Guillén (2014). Elasticidad precio-renovación en seguros de auto. *Expert Systems with Applications*.

Eling, Pradhan & Schmit (2014). Determinantes de demanda y dropout en microseguros: liquidez y confianza. *The Geneva Papers*.

Outreville (1990). Lapse en vida y la hipótesis del fondo de emergencia (EFH). *J. of Risk and Insurance*.

European Actuarial Journal (2022). Determinantes de lapse en vida — selección Lasso; duración temprana.

Meyers et al. (2019). Premium y calidad como drivers de cambio de plan de salud. *JAMA Internal Medicine*. ⚠ Contexto EE.UU.

Platteau et al. (2021). Sesgos y puzzle del sub-aseguramiento. *J. of Behavioral & Experimental Finance*.

REGULADORES Y GREMIOS (● SÓLIDA)

SBS (2023). Estudio de conocimiento y percepción de la demanda de seguros en Perú: tenencia, confianza, rol del broker.

APEIM (2024). Niveles socioeconómicos 2023-2024: distribución e ingreso por NSE.

S&P Global Ratings (2024). LatAm Insurance Sector View: macro, lapse y rescates.

CONTEXTO DIRECCIONAL (●/● — NO FUNDAMENTA EL DISEÑO)

Mordor Intelligence (2025). Informalidad y bancarización en Perú.

SBS / prensa (2024). Cambio normativo del desgravamen (structural break). ⚠ Confirmar con la norma.

Registro completo con rigurosidad por fuente: [research/fuentes/registro_fuentes.md](#) (F-1, F-3, F-35 a F-44).